Uczenie maszynowe: Raport – Etap 1

Tematyka projektu: Auto Insurance Claims Analysis (Analiza roszczeń ubezpieczeń komunikacyjnych).

1. Informacja o Zespole

Zadania w projekcie zostały podzielone równomiernie, z naciskiem na implementację programistyczną po stronie wskazanych osób, oraz analitykę i raportowanie u pozostałych członków zespołu.

Imię i Nazwisko	ID	Zakres obowiązków (Co kto robi)
Pavel Andreyenka	71885	Lead Programmer: Pisanie skryptów do parsowania danych numerycznych, implementacja statystyk EDA, rozwój klasycznych modeli ML.
Vadzim Presman	71913	Lead Programmer: Preprocessing danych tekstowych (NLP), pisanie skryptów integracyjnych, konfiguracja środowiska i repozytorium GitHub.
Mykyta Dushyn	72347	Data Analyst: Projektowanie analizy statystycznej, formułowanie pytań badawczych, weryfikacja statystyczna wyników EDA.
Dariia Lapina	72850	Data Analyst: Weryfikacja jakości źródeł danych, projektowanie i generowanie wizualizacji (wykresy) dla raportów, dokumentacja.
Oleksandr Holota	73939	Project Manager / UI: Koordynacja prac zespołu, przygotowanie raportów, projektowanie logiczne interfejsu analitycznego (Gradio).

2. Informacja o Danych

> **Podejście do danych:** Projekt korzysta z obu zbiorów danych w ich **pełnej postaci (całościowo)**. Nie stosujemy podzbiorów w początkowej fazie, aby zachować maksymalną wariancję w analizie.

Zgodnie z wymaganiami projektu, wykorzystujemy dwa publicznie dostępne zbiory danych z rzeczywistymi informacjami:

- **Zbiór 1 (Język naturalny):** *Auto Insurance Claims Narratives*. Zawiera on tekstowe opisy zdarzeń drogowych formułowane przez klientów zgłaszających szkodę, notatki rzeczoznawców oraz powody odrzucenia/akceptacji roszczenia.
  Link do zbioru danych
- **Zbiór 2 (Dane liczbowe):** *Vehicle Insurance Claim Fraud Detection / Cost Data*. Zawiera zmienne numeryczne i kategoryczne: wiek kierowcy, wartość ubezpieczonego pojazdu, kwotę roszczenia (Claim Amount), stawkę bazową oraz parametry techniczne.
  Link do zbioru danych

3. Pytania Badawcze

Na podstawie zebranych danych, zespół sformułował następujące pytania badawcze, na które odpowie z użyciem modeli nadzorowanych i nienadzorowanych (NLP oraz ML):

1. W jaki sposób występowanie konkretnych słów kluczowych i poziom złożoności opisu wypadku (dane tekstowe) koreluje z ostateczną wartością przyznanego odszkodowania (dane liczbowe)?
2. Czy na podstawie sentymentu i struktury narracji zgłoszenia (NLP) można z wyprzedzeniem przewidzieć anomalie liczbowe i potencjalne próby wyłudzenia ubezpieczenia?
3. Które cechy numeryczne (np. wiek kierowcy, staż polisy) determinują charakter opisywanych szkód (klastrowanie nienadzorowane tekstów dla konkretnych grup ryzyka)?

4. Analiza Eksploracyjna Danych (EDA)

Wstępna analiza danych (EDA) ma na celu zrozumienie rozkładu zmiennych, identyfikację wartości odstających (outliers) oraz określenie jakości tekstu w opisach zdarzeń.

Analiza Danych Liczbowych (Zbiór 2)

Za pomocą bibliotek statystycznych przebadano podstawowe metryki. Rozkład zmiennej celu, czyli kwoty roszczenia (*Claim Amount*), jest silnie prawostronnie skośny. Oznacza to, że większość zgłoszeń dotyczy drobnych kolizji o niskiej wartości, natomiast istnieje relatywnie mała, lecz istotna finansowo, grupa wypadków całkowitych. Przygotowano macierz korelacji, która wstępnie wskazuje, że wiek pojazdu i historia bezszkodowa są silnie powiązane z kwotą bazową polisy.

Analiza Danych Tekstowych (Zbiór 1)

W ramach analizy tekstowej obliczono średnią długość zgłoszenia, która wynosi około 45 słów, z istotną wariancją. Użyto tokenizacji, usunięto stop-words oraz znaki interpunkcyjne. Opracowano częstotliwość występowania słów (TF-IDF). Najczęściej pojawiające się terminy to m.in.: *"skrzyżowanie", "hamowanie", "zderzak", "nie zauważyłem", "warunki pogodowe"*. Zidentyfikowano również istnienie braków danych w tekstach (NaN), które stanowią około 3% zbioru i będą wymagały zastosowania technik imputacji.

5. Repozytorium GitHub

Cały kod źródłowy wykorzystany do powyższej analizy eksploracyjnej (skrypty i notatniki Jupyter) oraz instrukcje dostępu do pełnych wersji użytych zbiorów danych znajdują się w publicznym repozytorium zespołu.

> **Link do repozytorium:**
> **https://github.com/XedDevi1/Auto-Insurance-Claims-Analysis**

Raport przygotowany w ramach przedmiotu Uczenie Maszynowe.
Wszyscy członkowie zespołu zatwierdzili powyższy zakres zadań.